SOLUÇÕES DE AUTOMAÇÃO E OTIMIZAÇÃO LOGÍSTICA

Melhores Compras

Reconhecimento Facial e Clusterização Espacial

Beatriz Cassemiro Costa RM566271

Douglas Michel da Silva Costa RM564209

FIAP – Ciência de Dados

Outubro de 2026

1. Introdução

A Melhores Compras busca aplicar técnicas de Ciência de Dados e Inteligência Artificial para ampliar a eficiência operacional, reduzir custos e fortalecer sua competitividade no comércio eletrônico. Um dos desafios identificados está na logística de última milha: aproximadamente 13% das entregas não são concluídas na primeira tentativa, por ausência do cliente no endereço informado, o que pode gerar novas tentativas e custos adicionais.

Como alternativa, foi proposta a implantação de centros automatizados de retirada em regiões com maior concentração de falhas de entrega. Para avaliar a viabilidade técnica dessa proposta, este relatório apresenta dois protótipos: (1) detecção e comparação de faces para validar a identidade de um usuário; e (2) clusterização espacial das ocorrências de falha, visando estimar regiões candidatas à instalação de cinco mini-hubs.

2. Atividade 1 — Automação por Reconhecimento Facial

2.1 Objetivo

Verificar se um protótipo em Python consegue detectar um rosto em uma imagem e comparar a face de validação com imagens de referência da mesma pessoa. O experimento busca demonstrar o funcionamento básico de uma etapa de autenticação automatizada para os centros de retirada.

2.2 Ferramentas e metodologia

O código utiliza Python, OpenCV, NumPy e Matplotlib. O classificador Haar Cascade, disponibilizado pelo OpenCV, localiza a região da face (ROI). Em seguida, a imagem é convertida para escala de cinza e a região facial é redimensionada para 100 × 100 pixels, padronizando as matrizes comparadas.

Para cada pasta de pessoa, o programa ordena os arquivos de imagem, utiliza as quatro primeiras fotos como referências e reserva a quinta para validação. A face detectada na imagem de teste é comparada com cada matriz de referência por meio da distância euclidiana; o menor valor é selecionado. O código considera o reconhecimento bem-sucedido quando essa distância é inferior ao limiar definido de 7000.

2.3 Resultados e demonstração

Na execução registrada no notebook, o algoritmo processou cinco conjuntos de imagens. Em todos os conjuntos, a distância mínima ficou abaixo do limiar adotado e o programa exibiu o resultado “SIM”.

Conjunto de imagens	Menor distância euclidiana	Resultado
pessoa_1	5947,46	Sucesso
pessoa_2	4752,44	Sucesso
pessoa_3	4620,92	Sucesso
pessoa_4	6106,77	Sucesso
pessoa_5	4205,63	Sucesso

As imagens a seguir registram exemplos da execução do notebook, incluindo a face detectada, o valor de distância calculado e o resultado da comparação.

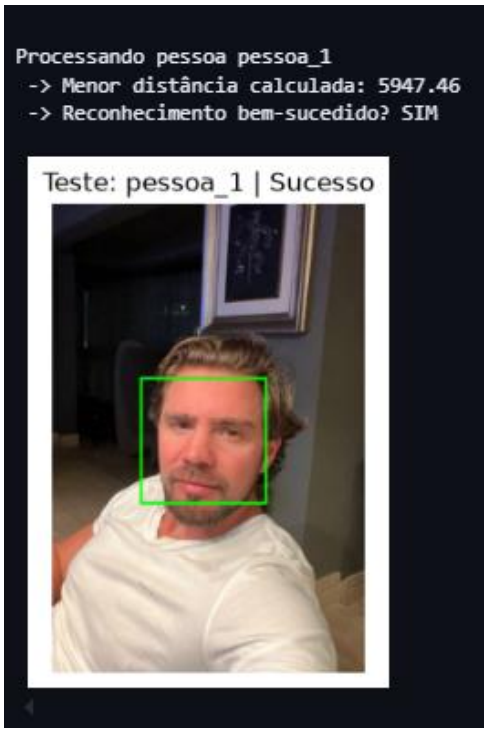


Figura 1 — Resultado da validação do conjunto pessoa_1.



Figura 2 — Resultado da validação do conjunto pessoa_4.

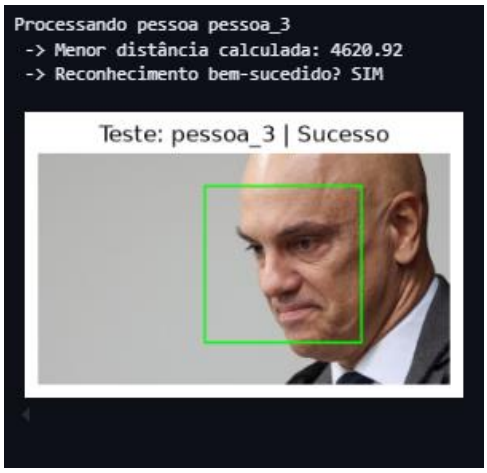


Figura 3 — Resultado da validação do conjunto pessoa_3.



Figura 4 — Resultado da validação do conjunto pessoa_5.



Figura 5 — Resultado da validação do conjunto pessoa_2.

2.4 Avaliação e limitações

Considerando os resultados registrados, o protótipo atingiu o critério de sucesso definido para os cinco conjuntos avaliados: em cada caso, a quinta imagem foi aceita pelo limiar de distância. Isso demonstra que o fluxo de detecção e comparação funciona nas condições testadas.

Entretanto, a comparação direta de pixels em escala de cinza é sensível a variações de iluminação, pose, expressão e enquadramento. Além disso, o limiar adotado não constitui, isoladamente, uma garantia de identidade: imagens de pessoas diferentes podem produzir distâncias semelhantes (*alguns testes deram falsos positivos*). Portanto, o experimento é uma prova de conceito, e não uma solução biométrica pronta para uso comercial. Antes de uma implantação real, seria necessário realizar testes com pessoas não cadastradas, medir falsos positivos e falsos negativos e avaliar métodos de reconhecimento facial baseados em embeddings e modelos de Deep Learning.

3. Atividade 2 — Otimização Logística e Clusterização (K-Means)

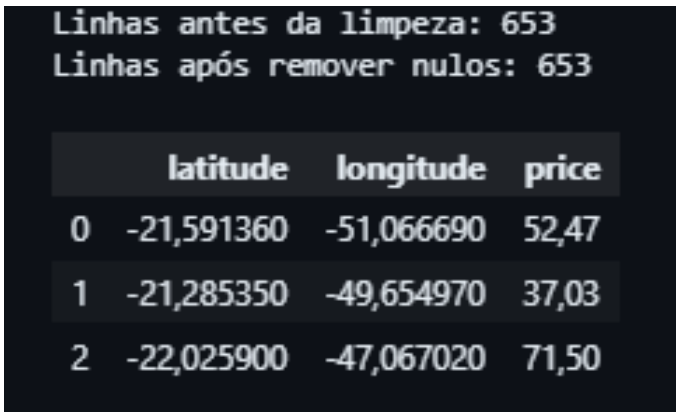
3.1 Objetivo e metodologia

O objetivo desta atividade é agrupar espacialmente os locais associados a falhas de entrega e estimar cinco regiões candidatas à instalação de mini-hubs. A base disponibilizada contém latitude, longitude e valor da entrega. Conforme o enunciado, as coordenadas são utilizadas apenas para aproximar a distribuição espacial dos pontos, não como geolocalizações reais.

Foi utilizado o algoritmo K-Means com k = 5. O método agrupa os registros em cinco clusters de acordo com a proximidade das coordenadas e calcula um centroide para cada grupo. O valor financeiro das entregas é então somado por cluster para estimar o montante associado a cada região.

3.2 Tratamento da base e resultados financeiros

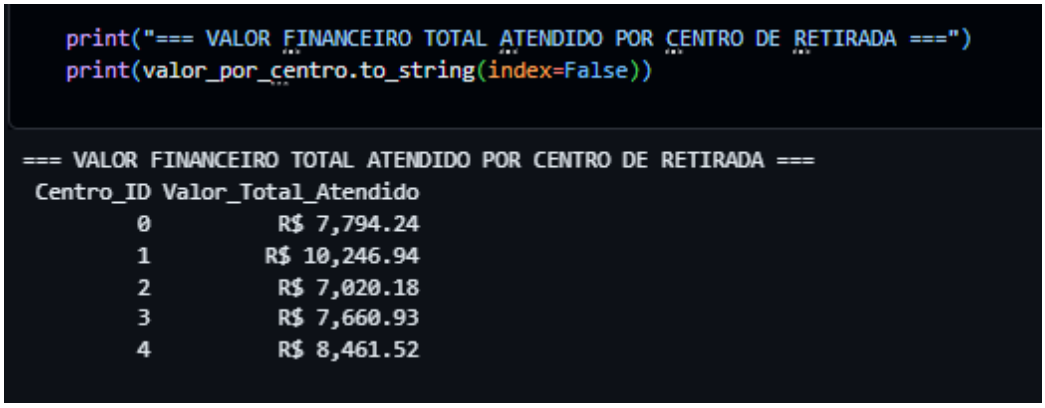
O processamento registrado indica que a base passou por uma etapa de limpeza, com 653 linhas antes e 653 linhas depois da remoção de nulos. A tabela exibida na execução apresenta os valores agregados por centro de retirada; a imagem abaixo foi mantida como evidência do resultado produzido pelo código.



```
Linhas antes da limpeza: 653
Linhas após remover nulos: 653
```

	latitude	longitude	price
0	-21,591360	-51,066690	52,47
1	-21,285350	-49,654970	37,03
2	-22,025900	-47,067020	71,50

Figura 6 — Registro da contagem de linhas após a limpeza e amostra dos dados.



```
print("=== VALOR FINANCEIRO TOTAL ATENDIDO POR CENTRO DE RETIRADA ===")
print(valor_por_centro.to_string(index=False))
```

```
=== VALOR FINANCEIRO TOTAL ATENDIDO POR CENTRO DE RETIRADA ===
 Centro_ID Valor_Total_Atendido
         0          R$ 7,794.24
         1         R$ 10,246.94
         2          R$ 7,020.18
         3          R$ 7,660.93
         4          R$ 8,461.52
```

Figura 7 — Valores financeiros totais apresentados para os cinco centros de retirada.

Centro de retirada (ID)	Valor total atendido
0	R$ 7.794,24
1	R$ 10.246,94
2	R$ 7.020,18

3	R$ 7.660,93
4	R$ 8.461,52

O resultado destacado no relatório original aponta o Centro 1 como prioridade de análise, com valor associado de R$ 10.246,94. Esse montante representa o valor das entregas agrupadas naquela região na base analisada; não deve ser interpretado automaticamente como economia garantida, pois o benefício real dependerá da adesão dos clientes, dos custos de implantação e operação e da proporção de entregas que poderá ser redirecionada aos mini-hubs.

3.3 Visualização geográfica

O gráfico de dispersão apresenta os pontos de falha coloridos por cluster e os centroides destacados por marcadores vermelhos. Como as coordenadas não são reais, a visualização permite comparar a distribuição relativa dos pontos e a posição matemática dos centroides, mas não indica diretamente endereços físicos para construção.

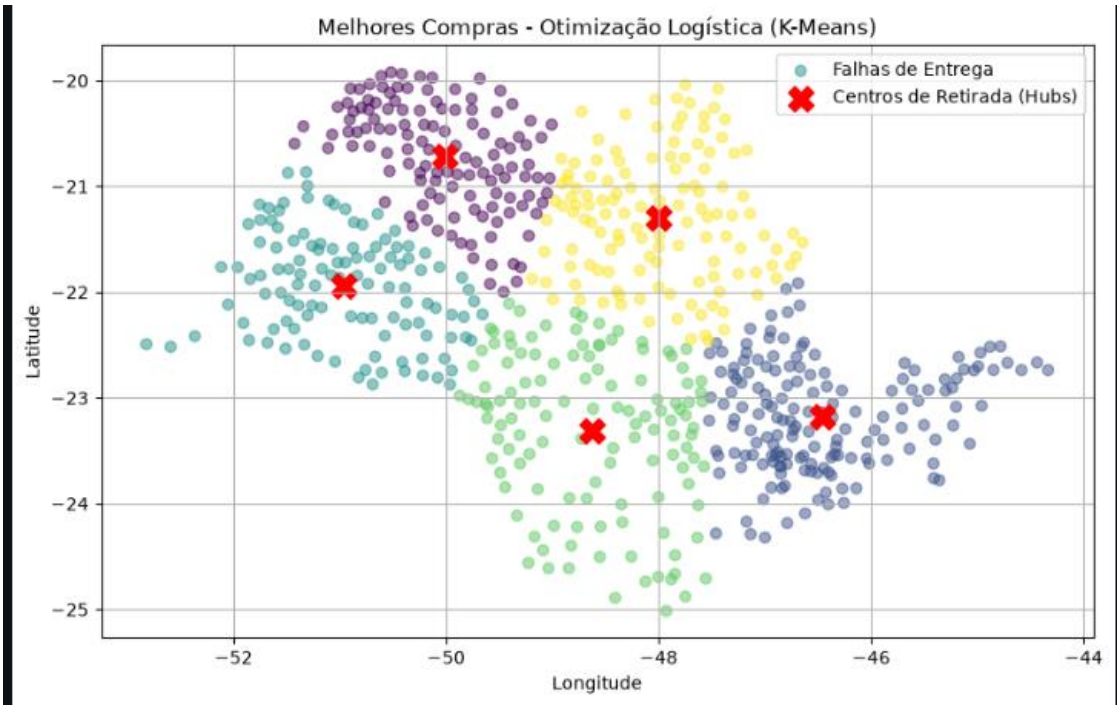


Figura 8 — Distribuição dos pontos de falha e centroides calculados pelo K-Means.

3.4 Avaliação e recomendação estratégica

A clusterização atende ao objetivo exploratório de dividir os registros em cinco grupos e estimar o valor financeiro associado a cada um. A análise sugere priorizar a região com maior valor agregado para uma investigação operacional mais detalhada.

Antes de definir a localização definitiva dos centros, recomenda-se validar os resultados com coordenadas reais e considerar fatores adicionais, como densidade de clientes, acessibilidade, segurança, custo de instalação, capacidade dos armários e distância até os usuários. Também seria importante comparar diferentes quantidades de clusters e avaliar a estabilidade dos agrupamentos. Assim, os centroides devem ser tratados como referências analíticas iniciais, não como locais de construção automaticamente ideais.

4. Conclusão final

Os dois protótipos demonstram como técnicas de visão computacional e aprendizado de máquina podem apoiar a modernização das operações da Melhores Compras. No reconhecimento facial, as cinco imagens de validação foram aceitas segundo o limiar definido, embora o método ainda precise de testes de segurança e de maior robustez antes de uma aplicação real. Na logística, o K-Means organizou os registros em cinco grupos espaciais e permitiu comparar o valor financeiro associado a cada cluster.

Em conjunto, os resultados oferecem evidências iniciais para investigar a automação dos centros de retirada e a priorização de regiões com maior concentração de falhas. A redução efetiva de custos e a recuperação de receita, contudo, deverão ser confirmadas por validação com dados reais, análise de viabilidade operacional e acompanhamento dos resultados após eventual implantação.